

# Avance de Proyecto U1

Probabilidad y Estadística

Análisis estadístico de factores asociados a la Diabetes Mellitus Tipo 2

## Integrantes:

Arellano González Raúl Antonio

Izquierdo Mendoza Steven

Quintal Chuc Juan Emiliano

Campos Chalé Cristian Jafet

**Materia:** Probabilidad y Estadística

**Docente:** Nombre del profesor

15 de junio de 2026

## Resumen

El presente avance de proyecto tiene como objetivo analizar estadísticamente algunos factores asociados a la Diabetes Mellitus Tipo 2 (DMT2) a partir de la base de datos *Pima Indians Diabetes Database*. Esta base contiene 768 observaciones de mujeres mayores o iguales a 21 años de herencia Pima Indian, e incluye variables clínicas como glucosa, presión arterial, índice de masa corporal, edad, número de embarazos, insulina y un índice de predisposición familiar. La variable de interés principal es **Outcome**, la cual indica si la paciente presenta o no diabetes. A partir de esta información, se plantea una exploración descriptiva mediante gráficas y medidas estadísticas de centralización, dispersión y localización, con el fin de identificar patrones preliminares en los datos.

# Índice

|                                                                |          |
|----------------------------------------------------------------|----------|
| <b>1. Planteamiento del problema</b>                           | <b>3</b> |
| <b>2. Contexto del proyecto</b>                                | <b>3</b> |
| <b>3. Objetivos</b>                                            | <b>4</b> |
| 3.1. Objetivo general . . . . .                                | 4        |
| 3.2. Objetivos específicos . . . . .                           | 4        |
| <b>4. Hipótesis</b>                                            | <b>4</b> |
| 4.1. Hipótesis general . . . . .                               | 4        |
| 4.2. Hipótesis específicas . . . . .                           | 4        |
| <b>5. Recolección de datos</b>                                 | <b>5</b> |
| <b>6. Variables del estudio</b>                                | <b>6</b> |
| <b>7. Gráficas propuestas</b>                                  | <b>6</b> |
| 7.1. Espacio para insertar figuras . . . . .                   | 6        |
| <b>8. Medidas de centralización, dispersión y localización</b> | <b>7</b> |
| 8.1. Medidas de centralización . . . . .                       | 7        |
| 8.2. Medidas de dispersión . . . . .                           | 7        |
| 8.3. Medidas de localización . . . . .                         | 7        |
| <b>9. Análisis preliminar esperado</b>                         | <b>8</b> |
| <b>10.Limitaciones del estudio</b>                             | <b>8</b> |
| <b>11.Conclusiones hasta el momento</b>                        | <b>8</b> |
| <b>12.Referencias</b>                                          | <b>9</b> |

# 1. Planteamiento del problema

La Diabetes Mellitus Tipo 2 es una enfermedad crónica que representa un problema importante de salud pública debido a su alta frecuencia y a las complicaciones que puede generar a largo plazo. Desde el punto de vista estadístico, resulta relevante estudiar qué variables clínicas y demográficas presentan mayor asociación con la presencia de diabetes en una población determinada.

En este proyecto se utilizará la base de datos *Pima Indians Diabetes Database*. La base contiene 768 registros y 9 variables, de las cuales 8 corresponden a variables predictoras y 1 al resultado binario de diabetes (**Outcome**).

A partir de estos datos, se busca responder la siguiente pregunta de investigación:

*¿Qué variables clínicas presentan mayor relación con la presencia de diabetes en la base de datos Pima Indians Diabetes Database?*

# 2. Contexto del proyecto

La base de datos seleccionada es un conjunto clásico utilizado en análisis estadístico y aprendizaje automático para estudiar la predicción de diabetes. Su objetivo original es diagnosticar si una paciente presenta diabetes a partir de distintas mediciones clínicas. Entre sus características principales se encuentra que todas las observaciones corresponden a mujeres adultas (21 años o más) de herencia Pima Indian.

Las variables incluidas en la base son:

- **Pregnancies**: número de embarazos.
- **Glucose**: concentración de glucosa plasmática.
- **BloodPressure**: presión arterial diastólica.
- **SkinThickness**: grosor del pliegue cutáneo del tríceps.
- **Insulin**: nivel de insulina sérica a 2 horas.
- **BMI**: índice de masa corporal.
- **DiabetesPedigreeFunction**: indicador asociado a predisposición familiar/genética.
- **Age**: edad.
- **Outcome**: resultado de diabetes (0 = no diabetes, 1 = diabetes).

Esta base resulta adecuada para el curso porque permite aplicar conceptos de estadística descriptiva, probabilidad y análisis exploratorio de datos.

## 3. Objetivos

### 3.1. Objetivo general

Analizar estadísticamente la relación entre variables clínicas y la presencia de diabetes en la base de datos *Pima Indians Diabetes Database*.

### 3.2. Objetivos específicos

1. Describir la base de datos y sus variables principales.
2. Identificar las variables de mayor interés para el estudio de diabetes.
3. Elaborar gráficas descriptivas para explorar la distribución de los datos.
4. Calcular medidas de centralización, dispersión y localización para variables numéricas seleccionadas.
5. Formular conclusiones preliminares sobre la asociación entre ciertas variables y la presencia de diabetes.

## 4. Hipótesis

### 4.1. Hipótesis general

Las pacientes con mayores niveles de glucosa, mayor índice de masa corporal, mayor edad y mayor predisposición familiar presentan mayor probabilidad de resultar positivas en la variable `Outcome`.

### 4.2. Hipótesis específicas

- H1: Existe una relación positiva entre la glucosa y la presencia de diabetes.
- H2: Un mayor índice de masa corporal se asocia con mayor probabilidad de diabetes.
- H3: La edad tiene una relación positiva con la presencia de diabetes.
- H4: Una mayor predisposición familiar, representada por `DiabetesPedigreeFunction`, se asocia con un mayor riesgo de diabetes.

## 5. Recolección de datos

La recolección de datos en este proyecto no se realizó mediante encuesta propia, sino a través de una fuente secundaria pública. Se empleó la base de datos *Pima Indians Diabetes Database*, disponible en Kaggle.

La base contiene 768 observaciones y 9 variables. Para este avance se trabajará principalmente con las siguientes variables:

- Outcome
- Glucose
- BMI
- Age
- DiabetesPedigreeFunction

Estas variables se eligieron porque permiten representar dimensiones relevantes del problema:

- Estado de diabetes: Outcome
- Factor metabólico: Glucose
- Composición corporal: BMI
- Factor demográfico: Age
- Predisposición familiar/genética: DiabetesPedigreeFunction

## 6. Variables del estudio

Cuadro 1: Variables principales del proyecto

| Variable                 | Tipo                              | Descripción                                       |
|--------------------------|-----------------------------------|---------------------------------------------------|
| Outcome                  | Cualitativa nominal<br>dicotómica | Indica si la paciente tiene diabetes (1) o no (0) |
| Glucose                  | Cuantitativa continua             | Concentración de glucosa en plasma                |
| BMI                      | Cuantitativa continua             | Índice de masa corporal                           |
| Age                      | Cuantitativa discreta             | Edad de la paciente en años                       |
| DiabetesPedigreeFunction | Cuantitativa continua             | Índice de predisposición familiar/genética        |
| Pregnancies              | Cuantitativa discreta             | Número de embarazos                               |
| BloodPressure            | Cuantitativa continua             | Presión arterial diastólica                       |

## 7. Gráficas propuestas

Para el análisis exploratorio se propone elaborar las siguientes gráficas:

1. Histograma de edad.
2. Histograma de glucosa.
3. Gráfica de barras de Outcome.
4. Diagrama de caja (*boxplot*) de Glucose por Outcome.
5. Gráfica de dispersión de BMI vs Glucose.

### 7.1. Espacio para insertar figuras

Figura 1: Histograma de la variable Edad.

Figura 2: Histograma de la variable Glucosa.

Figura 3: Frecuencia de pacientes con y sin diabetes.

Figura 4: Comparación de glucosa según el resultado de diabetes.

## 8. Medidas de centralización, dispersión y localización

En esta etapa del proyecto se propone calcular medidas estadísticas para las variables numéricas principales, especialmente Glucose, BMI, Age y BloodPressure.

### 8.1. Medidas de centralización

Las medidas de centralización que se utilizarán son:

- Media aritmética
- Mediana
- Moda

### 8.2. Medidas de dispersión

Se calcularán:

- Rango
- Varianza
- Desviación estándar

### 8.3. Medidas de localización

Se incluirán:

- Cuartiles
- Percentiles

Cuadro 2: Medidas estadísticas descriptivas propuestas

| Medida              | Glucose | BMI | Age | BloodPressure |
|---------------------|---------|-----|-----|---------------|
| Media               | —       | —   | —   | —             |
| Mediana             | —       | —   | —   | —             |
| Moda                | —       | —   | —   | —             |
| Rango               | —       | —   | —   | —             |
| Varianza            | —       | —   | —   | —             |
| Desviación estándar | —       | —   | —   | —             |
| Q1                  | —       | —   | —   | —             |
| Q2                  | —       | —   | —   | —             |
| Q3                  | —       | —   | —   | —             |

## 9. Análisis preliminar esperado

Con base en la naturaleza de las variables incluidas, se espera encontrar que las pacientes con diabetes presenten, en promedio, niveles de glucosa más altos, valores de IMC mayores y edades relativamente superiores a las del grupo sin diabetes.

Asimismo, se considera posible encontrar una relación entre el índice `DiabetesPedigreeFunction` y el diagnóstico, ya que esta variable representa una medida vinculada con predisposición familiar/genética.

## 10. Limitaciones del estudio

Es importante señalar que este conjunto de datos no representa a toda la población general, ya que está conformado únicamente por mujeres adultas de herencia Pima Indian. Por esta razón, los resultados obtenidos no deben generalizarse automáticamente a otros grupos poblacionales.

Además, algunas variables presentan valores de cero que no son fisiológicamente consistentes, lo que sugiere la presencia de datos faltantes o problemas de captura. Este aspecto deberá considerarse cuidadosamente en etapas posteriores del análisis.

## 11. Conclusiones hasta el momento

Hasta esta etapa del proyecto se ha definido el problema de investigación, seleccionado una base de datos adecuada y establecido las variables principales para el análisis estadís-



tico. La base *Pima Indians Diabetes Database* ofrece una estructura clara, con variables clínicas relevantes para estudiar la presencia de diabetes.

De manera preliminar, se espera que variables como la glucosa, el índice de masa corporal, la edad y la predisposición familiar presenten asociación con el diagnóstico de diabetes. En la siguiente fase del proyecto se procederá a limpiar los datos, generar las gráficas correspondientes y calcular las medidas estadísticas descriptivas para sustentar o rechazar las hipótesis propuestas.

## 12. Referencias

### Referencias

- [1] UCI ML Repository, “Pima Indians Diabetes Database,” Kaggle. [En línea]. Disponible en: <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>. [Accedido: 09-jun-2026].
- [2] F. Leisch and E. Dimitriadou, “PimaIndiansDiabetes,” mlbench R Documentation. [En línea]. Disponible en: <https://search.r-project.org/CRAN/refmans/mlbench/html/PimaIndiansDiabetes.html>. [Accedido: 09-jun-2026].
- [3] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler and R. S. Johannes, “Using the ADAP learning algorithm to forecast the onset of diabetes mellitus,” in *Proceedings of the Symposium on Computer Applications and Medical Care*, 1988, pp. 261–265.